1. Titre et contexte

Projet : Analyse et Ingénierie des données de la Chlordécone aux Antilles françaises

Auteur : Nawal El Hamdaoui

Objectif : Nettoyage, ingénierie des données, analyses avancées, spatialisation, ACP, clustering, modèles prédictifs.

2. Import des librairies

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
from sklearn.cluster import KMeans
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestRegressor

import missingno as msno
import folium
from folium.plugins import HeatMap
```

3. Chargement des deux bases (XLSX et CSV)

```
df_csv = pd.read_csv("/content/BaseCLD2026.csv", sep=";", encoding="latin1",
df_csv.columns.tolist()
```

```
['ID',
 'ANNEE',
 'COMMU_LAB',
 'RAIN',
 'Sol_simple',
 'type_sol',
 'Date_prelevement',
```

```
 'Date_enregistrement',
 'Date_analyse',
 'Operateur_chld',
 'Taux_Chlordecone',
 'Operateur_5b',
 'Taux_5b_hydro',
 'histoBanane_Histo_ban',
 'mnt_tpi_mean',
 'mnt_tri_mean',
 'mnt_rugosite_mean',
 'mnt_ombrage_mean',
 'mnt_exposition_mean',
 'mnt_pente_mean',
 'X',
 'Y']
```

```
df_csv.columns = df_csv.columns.str.strip()
```

```
df_xls = pd.read_excel("/content/BaseCLD2026.xlsx")
```

```
df_csv.columns.tolist()
```

```
['ID',
 'ANNEE',
 'COMMU_LAB',
 'RAIN',
 'Sol_simple',
 'type_sol',
 'Date_prelevement',
 'Date_enregistrement',
 'Date_analyse',
 'Operateur_chld',
 'Taux_Chlordecone',
 'Operateur_5b',
 'Taux_5b_hydro',
 'histoBanane_Histo_ban',
 'mnt_tpi_mean',
 'mnt_tri_mean',
 'mnt_rugosite_mean',
 'mnt_ombrage_mean',
 'mnt_exposition_mean',
 'mnt_pente_mean',
 'X',
 'Y']
```

4. Comparaison rapide des deux fichiers

```
print("XLSX shape :", df_xls.shape)
print("CSV shape  :", df_csv.shape)
print("Colonnes XLSX :", df_xls.columns.tolist())
print("Colonnes CSV  :", df_csv.columns.tolist())
print("Même ensemble de colonnes ? ", set(df_xls.columns) == set(df_csv.colu
```

```
XLSX shape : (31127, 22)
CSV shape  : (31126, 22)
Colonnes XLSX : ['Unnamed: 0', 'Unnamed: 1', 'Unnamed: 2', 'Unnamed: 3', 'Unn
Colonnes CSV  : ['ID', 'ANNEE', 'COMMU_LAB', 'RAIN', 'Sol_simple', 'type_sol'
Même ensemble de colonnes ?  False
```

5. Choix d’une base de travail principale

```
# 6. Choix de la base principale (ici XLSX, supposée plu
df = df_csv.copy()
df.head()
```

	ID	ANNEE	COMMU_LAB	RAIN	Sol_simple	type_sol	Date_prelevement	D
0	20143	2010	GROS-MORNE	2000-3000	Andosol	Intergrades Sols â□¦ allophane relativement â□...	24/05/2007	
1	20143	2010	GROS-MORNE	2000-3000	Andosol	Intergrades Sols â□¦ allophane relativement â□...	24/05/2007	
2	20143	2010	GROS-MORNE	2000-3000	Andosol	Intergrades Sols â□¦ allophane relativement â□...	24/05/2007	
3	20143	2010	GROS-MORNE	2000-3000	Andosol	Intergrades Sols â□¦ allophane relativement â□...	24/05/2007	
4	20143	2010	GROS-MORNE	2000-3000	Andosol	Intergrades Sols â□¦ allophane relativement â□...	24/05/2007	

5 rows × 22 columns

6. Inspection initiale de la base principale

```
# 7. Inspection initiale
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 31126 entries, 0 to 31125
Data columns (total 22 columns):
 #   Column                 Non-Null Count  Dtype
---  ------                 --------------  -----
 0   ID                     31126 non-null  int64
 1   ANNEE                  31126 non-null  int64
 2   COMMU_LAB              30828 non-null  object
 3   RAIN                   31126 non-null  object
 4   Sol_simple             31052 non-null  object
 5   type_sol               28517 non-null  object
 6   Date_prelevement       31126 non-null  object
 7   Date_enregistrement    31126 non-null  object
 8   Date_analyse           31126 non-null  object
 9   Operateur_chld         31126 non-null  object
 10  Taux_Chlordecone       31126 non-null  float64
 11  Operateur_5b           31126 non-null  object
 12  Taux_5b_hydro          31114 non-null  object
 13  histoBanane_Histo_ban  13143 non-null  float64
 14  mnt_tpi_mean           31098 non-null  float64
 15  mnt_tri_mean           31098 non-null  float64
 16  mnt_rugosite_mean      31098 non-null  float64
 17  mnt_ombrage_mean       31098 non-null  float64
 18  mnt_exposition_mean    31098 non-null  float64
 19  mnt_pente_mean         31098 non-null  float64
 20  X                      31126 non-null  float64
 21  Y                      31126 non-null  float64
dtypes: float64(10), int64(2), object(10)
memory usage: 5.2+ MB
```

8. Statistiques descriptives globales

```
# 8. Statistiques descriptives
df.describe(include='all')
```

	ID	ANNEE	COMMU_LAB	RAIN	Sol_simple	type_so
count	31126.000000	31126.000000	30828	31126	31052	2851
unique	NaN	NaN	35	6	7	4
top	NaN	NaN	MORNE-ROUGE(LE)	2000-3000	Andosol	Sols â allophan relativemer pe â voluâ
freq	NaN	NaN	3725	17425	10953	579
mean	38451.270449	2015.318994	NaN	NaN	NaN	Nal
std	19380.547105	2.816359	NaN	NaN	NaN	Nal
min	20003.000000	2010.000000	NaN	NaN	NaN	Nal
25%	21868.000000	2013.000000	NaN	NaN	NaN	Nal
50%	23412.000000	2016.000000	NaN	NaN	NaN	Nal
75%	62783.750000	2018.000000	NaN	NaN	NaN	Nal
max	63714.000000	2019.000000	NaN	NaN	NaN	Nal

11 rows × 22 columns

9. Valeurs manquantes et doublons

```
df.isnull().sum().sort_values(ascending=False), df.dupli
```

```
(histoBanane_Histo_ban    17983
 type_sol                  2609
 COMMU_LAB                  298
 Sol_simple                  74
 mnt_rugosite_mean           28
 mnt_pente_mean              28
 mnt_ombrage_mean            28
 mnt_tpi_mean                28
 mnt_tri_mean                28
 mnt_exposition_mean         28
 Taux_5b_hydro               12
 RAIN                         0
 ID                           0
 ANNEE                        0
 Taux_Chlordecone             0
 Operateur_5b                 0
 Date_analyse                 0
 Operateur_chld               0
 Date_enregistrement          0
 Date_prelevement             0
 X                            0
 Y                            0
 dtype: int64,
 np.int64(8))
```

10. Nettoyage des dates

```
date_cols = ["Date_prelevement", "Date_enregistrement",

for col in date_cols:
    df[col] = pd.to_datetime(df[col], errors='coerce', c

df[date_cols].head()
```

	Date_prelevement	Date_enregistrement	Date_analyse
0	2007-05-24	2007-05-24	2007-05-24
1	2007-05-24	2007-05-24	2007-05-24
2	2007-05-24	2007-05-24	2007-05-24
3	2007-05-24	2007-05-24	2007-05-24
4	2007-05-24	2007-05-24	2007-05-24

11. Nettoyage du Taux_Chlordecone

```
df["Taux_Chlordecone"] = (
    df["Taux_Chlordecone"].astype(str)
    .str.replace(",", ".", regex=False)
    .str.replace("<", "", regex=False)
    .str.replace("=", "", regex=False)
)

df["Taux_Chlordecone"] = pd.to_numeric(df["Taux_Chlordec
df["Taux_Chlordecone"].describe()
```

	Taux_Chlordecone
count	31126.000000
mean	0.667663
std	1.559895
min	0.001000
25%	0.002400
50%	0.003300
75%	0.410000
max	17.350000

dtype: float64

12. Nettoyage du Taux_5b_hydro

```
df["Taux_5b_hydro"] = df["Taux_5b_hydro"].replace("inf", np.nan)
df["Taux_5b_hydro"] = df["Taux_5b_hydro"].replace("Inf", np.nan)
df["Taux_5b_hydro"] = df["Taux_5b_hydro"].replace("INF", np.nan)
```

```
df["Taux_5b_hydro"] = (
    df["Taux_5b_hydro"].astype(str)
    .str.replace(",", ".", regex=False)
    .str.replace("<", "", regex=False)
    .str.replace("=", "", regex=False)
)
df["Taux_5b_hydro"] = pd.to_numeric(df["Taux_5b_hydro"],

df["Taux_5b_hydro"].describe()
```

	Taux_5b_hydro
count	30517.000000
mean	4.535388
std	67.026930
min	0.000000
25%	0.001000
50%	0.003300
75%	0.015000
max	999.000000

dtype: float64

13. Nettoyage des variables topographiques

```
topo_cols = [
    "mnt_tpi_mean","mnt_tri_mean","mnt_rugosite_mean",
    "mnt_ombrage_mean","mnt_exposition_mean","mnt_pente_
]

for col in topo_cols:
    df[col] = df[col].astype(str).str.replace(",", ".",
    df[col] = pd.to_numeric(df[col], errors="coerce")

df[topo_cols].describe()
```

	mnt_tpi_mean	mnt_tri_mean	mnt_rugosite_mean	mnt_ombrage_mean	mnt_e
count	31098.000000	31098.000000	31098.000000	31098.000000	
mean	0.211817	4.313287	13.444068	175.028425	
std	2.579504	2.858759	8.625712	27.893867	
min	-29.065807	0.000000	0.000000	24.789383	
25%	-0.875000	2.375000	7.500000	159.390883	
50%	0.120032	3.821790	12.000000	177.102983	
75%	1.266881	5.625000	17.764202	193.293212	
max	26.011950	29.358208	85.396165	255.000000	

14. Suppression des doublons

```
df = df.drop_duplicates()
df.shape
```

```
(31118, 22)
```

15. Recodage des types de sols

```
df["Sol_simple"] = df["Sol_simple"].astype(str).str.stri
df["type_sol"] = df["type_sol"].astype(str).str.strip()
df["Sol_simple"].value_counts()
```

Sol_simple	count
ANDOSOL	10946
VERTISOL	6921
FERRALSOL	5182
NITISOL	3062
NO DATA	2617
ALLUVIUM, COLLUVIUM	1604
URBAN AREA	712
NAN	74

dtype: int64

16. Création de classes de contamination

```
df["Classe_Chlordecone"] = pd.cut(
    df["Taux_Chlordecone"],
    bins=[0, 0.01, 0.1, 1, 10, 100],
    labels=["Très faible", "Faible", "Modérée", "Élevée"
    include_lowest=True
)

df["Classe_Chlordecone"].value_counts()
```

Classe_Chlordecone	count
Très faible	16926
Élevée	5438
Modérée	5217
Faible	3423
Très élevée	114

dtype: int64

17. Statistiques par commune et type de sol

```
df.groupby("COMMU_LAB")["Taux_Chlordecone"].median().sor
```

COMMU_LAB	Taux_Chlordecone
MORNE-ROUGE(LE)	2.7580
MACOUBA	1.5000
GRAND'RIVIERE	0.3363
LORRAIN(LE)	0.1850
MARIGOT(LE)	0.1250
BASSE-POINTE	0.0900
Hors Martinique	0.0630
TRINITE(LA)	0.0600
SAINT-ESPRIT	0.0400
SAINTE-MARIE	0.0190

dtype: float64

```
df.groupby("Sol_simple")["Taux_Chlordecone"].median().sc
```

Sol_simple	Taux_Chlordecone
NAN	0.2760
ANDOSOL	0.0900
ALLUVIUM, COLLUVIUM	0.0570
NO DATA	0.0200
FERRALSOL	0.0033
NITISOL	0.0033
URBAN AREA	0.0033
VERTISOL	0.0033

dtype: float64

18. Histogramme du taux de chlordécone

```
plt.figure(figsize=(8,4))
sns.histplot(df["Taux_Chlordecone"], bins=50, kde=True)
plt.xscale("log")
plt.title("Distribution du taux de chlordécone")
plt.show()
```

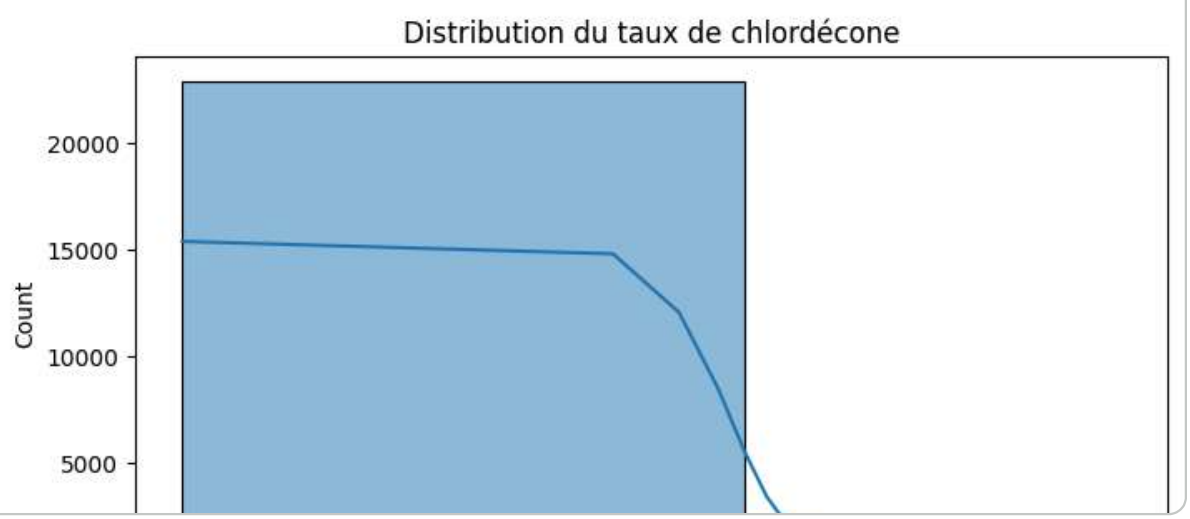

Interprétation

La distribution du taux de chlordécone est extrêmement asymétrique. La majorité des parcelles présentent des concentrations très faibles (souvent inférieures à 0,01 mg/kg), ce qui explique le pic massif à gauche du graphique. Cependant, une queue longue apparaît vers la droite : quelques parcelles présentent des valeurs nettement plus élevées, parfois supérieures à 10 mg/kg. Cette structure indique une

contamination localisée, concentrée dans certaines zones ou types de sols, plutôt qu'un phénomène homogène sur l'ensemble du territoire.

```
plt.tight_layout()
```

```
<Figure size 640x480 with 0 Axes>
```

19. Boxplot par type de sol

```
plt.figure(figsize=(12,6))
sns.boxplot(data=df, x="Sol_simple", y="Taux_Chlordecone
plt.xticks(rotation=90)
plt.yscale("log")
plt.title("Taux de chlordécone par type de sol")
plt.show()
```

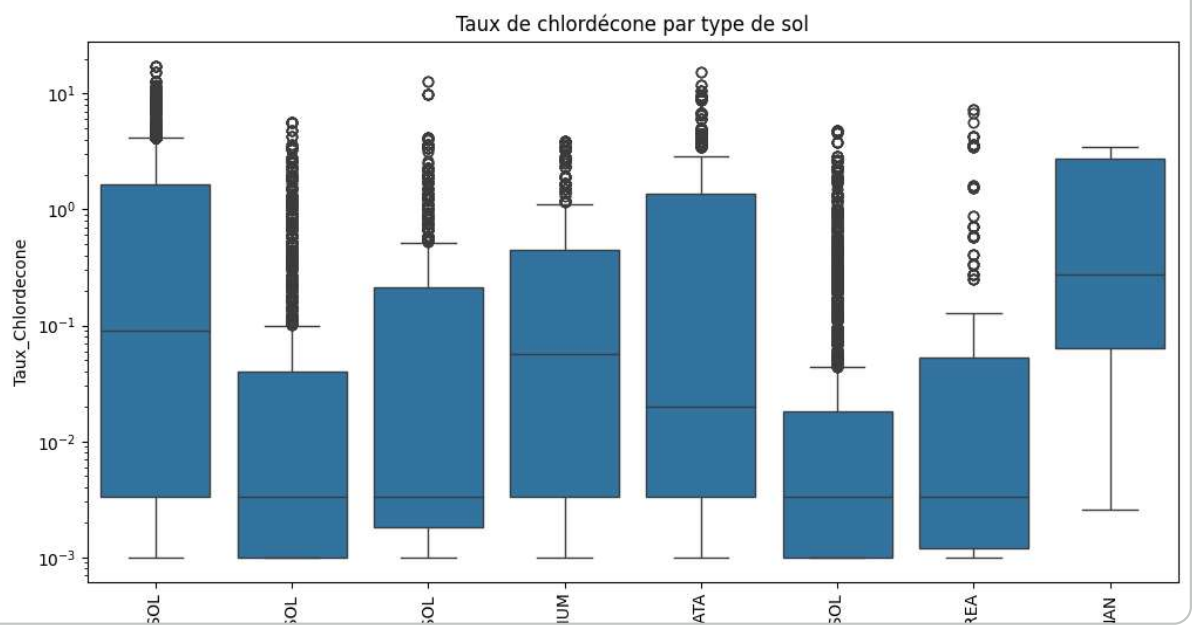

Interprétation

Les Andosols sont clairement les sols les plus contaminés, avec des médianes et des valeurs extrêmes très élevées. Cela correspond aux connaissances agronomiques : les Andosols, riches en allophane, fixent fortement le chlordécone, ce qui entraîne une accumulation durable.

Les Vertisols, Ferralsols, Nitisols et Urban Area présentent des niveaux beaucoup plus faibles, souvent proches de la limite de quantification.

Les Alluvium/Colluvium montrent une contamination intermédiaire, probablement liée à des phénomènes de ruissellement et de transport sédimentaire.

La catégorie No data est hétérogène et doit être interprétée avec prudence.

```
plt.tight_layout()
```

```
<Figure size 640x480 with 0 Axes>
```

20. Boxplot par commune

```
plt.figure(figsize=(12,6))
sns.boxplot(data=df, x="COMMU_LAB", y="Taux_Chlordecone"
plt.xticks(rotation=90)
plt.yscale("log")
plt.title("Taux de chlordécone par commune")
plt.show()
```

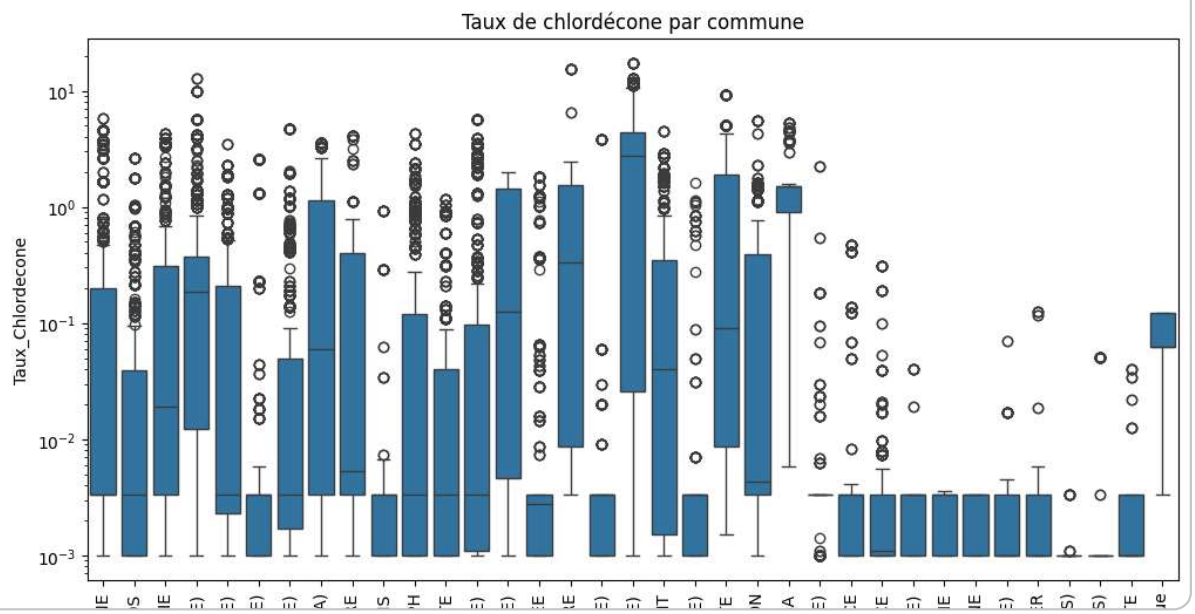

Carte interactive

```
m = folium.Map(location=[df["Y"].mean(), df["X"].mean()]

HeatMap(df[["Y","X","Taux_Chlordecone"]].dropna().values

m
```

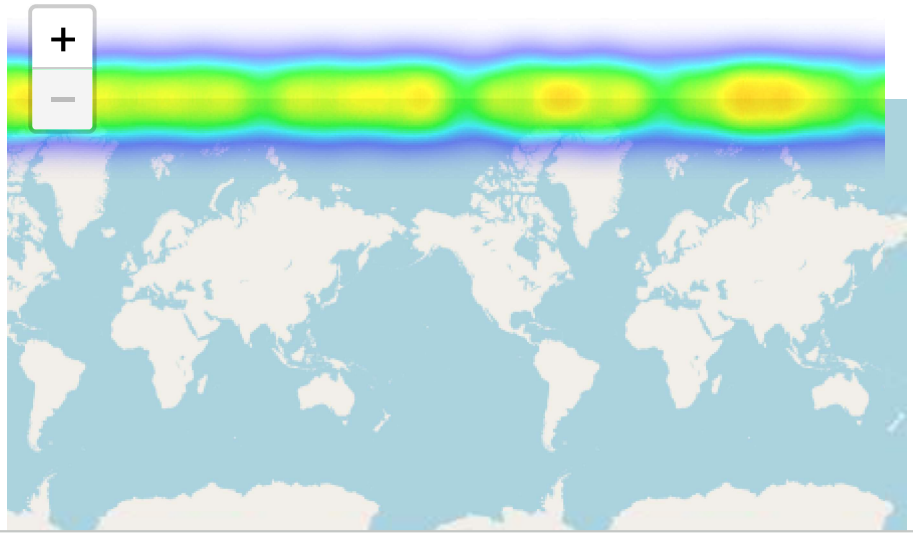

`Interprétation`

Certaines communes du Nord de la Martinique (Morne-Rouge, Macouba, Grand'Rivière) présentent des niveaux de contamination nettement supérieurs aux autres. Ces zones correspondent historiquement à des zones de culture intensive de banane, où le chlordécone a été massivement utilisé.

Les communes du Centre et du Sud montrent des niveaux beaucoup plus faibles, confirmant une contamination géographiquement concentrée.

La variabilité intra-communale est importante : certaines communes présentent des parcelles très contaminées et d'autres presque indemnes, ce qui reflète la diversité des sols et des pratiques agricoles.

```
plt.tight_layout()
```

```
<Figure size 640x480 with 0 Axes>
```

21. Matrice de corrélation (variables numériques)

```
plt.figure(figsize=(10,8))
sns.heatmap(df.corr(numeric_only=True), cmap="coolwarm")
plt.title("Matrice de corrélation")
plt.show()
```

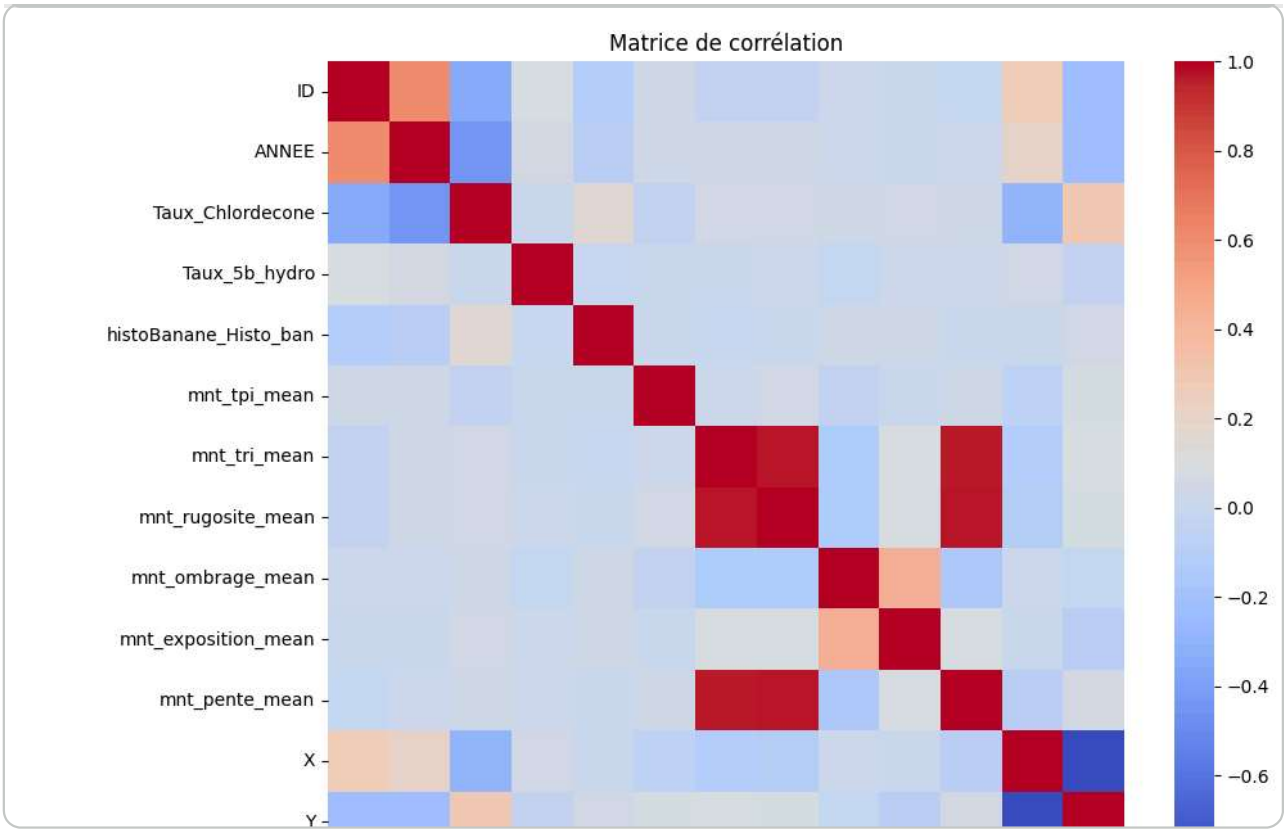

Interprétation

Le taux de chlordécone présente :

une corrélation faible à modérée avec certaines variables topographiques (pente, rugosité, exposition),

une corrélation quasi nulle avec les coordonnées X et Y (ce qui est normal : la localisation brute ne suffit pas à expliquer la contamination),

une corrélation positive avec le TPI et la rugosité dans certaines zones, suggérant que les zones en creux ou à faible pente peuvent favoriser l'accumulation.

La matrice montre que les variables topographiques sont entre elles fortement corrélées, ce qui justifie l'usage d'une ACP pour réduire la dimensionnalité.

```
plt.tight_layout()
```

```
<Figure size 640x480 with 0 Axes>
```

22. Carte simple X–Y colorée par taux

```
plt.figure(figsize=(8,8))
plt.scatter(df["X"], df["Y"], c=df["Taux_Chlordecone"],
plt.colorbar(label="Taux de chlordécone")
plt.title("Carte des parcelles contaminées")
plt.xlabel("X")
plt.ylabel("Y")
plt.show()
```

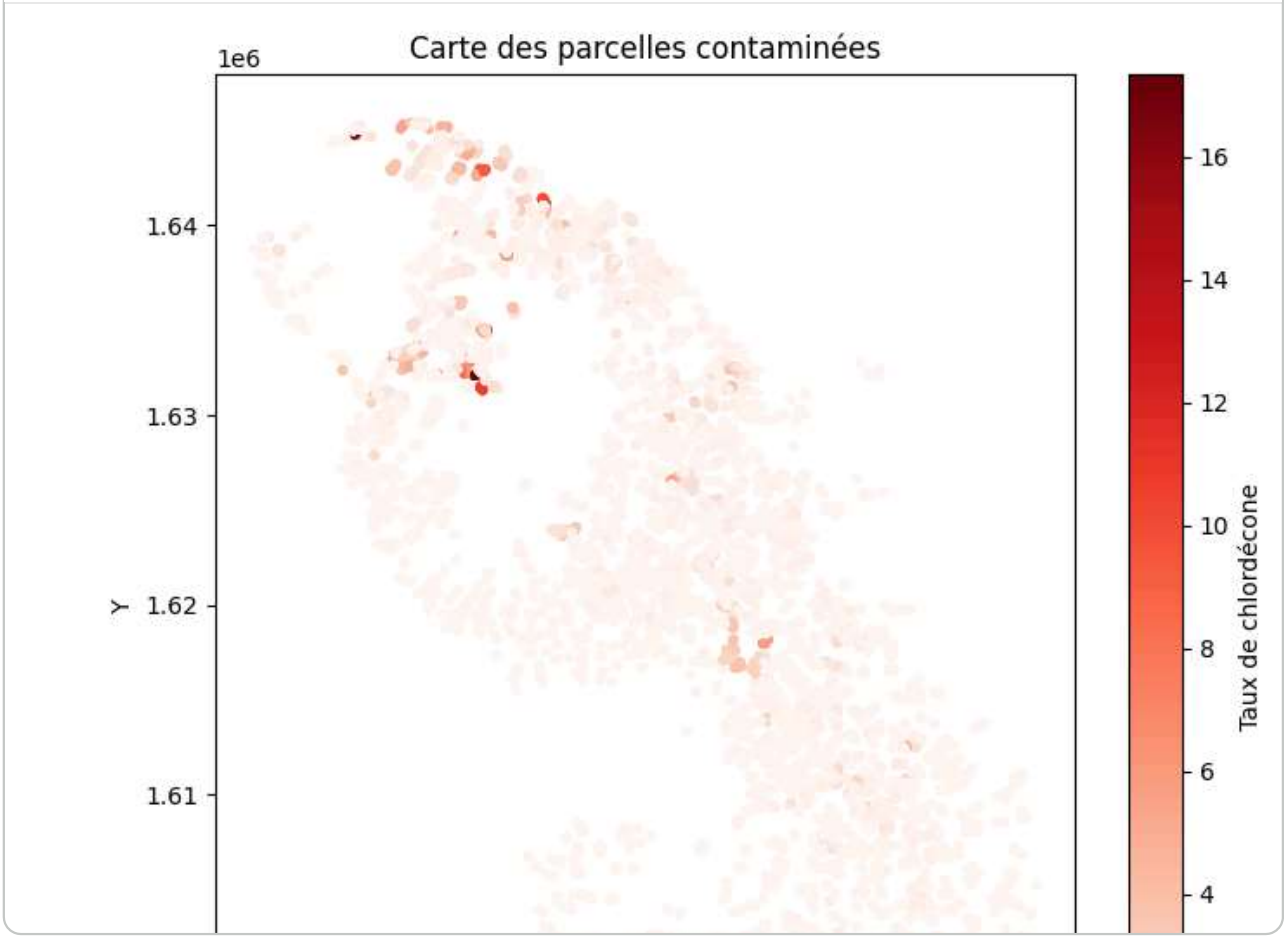

Interprétation

La carte révèle une forte hétérogénéité spatiale. Les points rouges foncés (forte contamination) se concentrent dans :

le Nord Atlantique (Morne-Rouge, Macouba, Grand'Rivière),

certaines zones de Sainte-Marie et Trinité.

Les zones du Sud et du Centre montrent une contamination faible à très faible.

Cette carte confirme que la contamination est géographiquement structurée, en lien avec :

l'histoire agricole (bananeraies),

la nature des sols,

la topographie.

```
plt.tight_layout()
```

```
<Figure size 640x480 with 0 Axes>
```

23. Préparation des données pour ACP / clustering

```
features = ["Taux_Chlordecone"] + topo_cols
X = df[features].dropna()

scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

24. ACP sur variables topographiques + contamination

```
pca = PCA(n_components=2)
pca_res = pca.fit_transform(X_scaled)

plt.figure(figsize=(6,5))
plt.scatter(pca_res[:,0], pca_res[:,1], c=X["Taux_Chlorc
plt.colorbar(label="Taux de chlordécone")
plt.title("ACP – topographie + contamination")
plt.xlabel("PC1")
plt.ylabel("PC2")
plt.show()
```

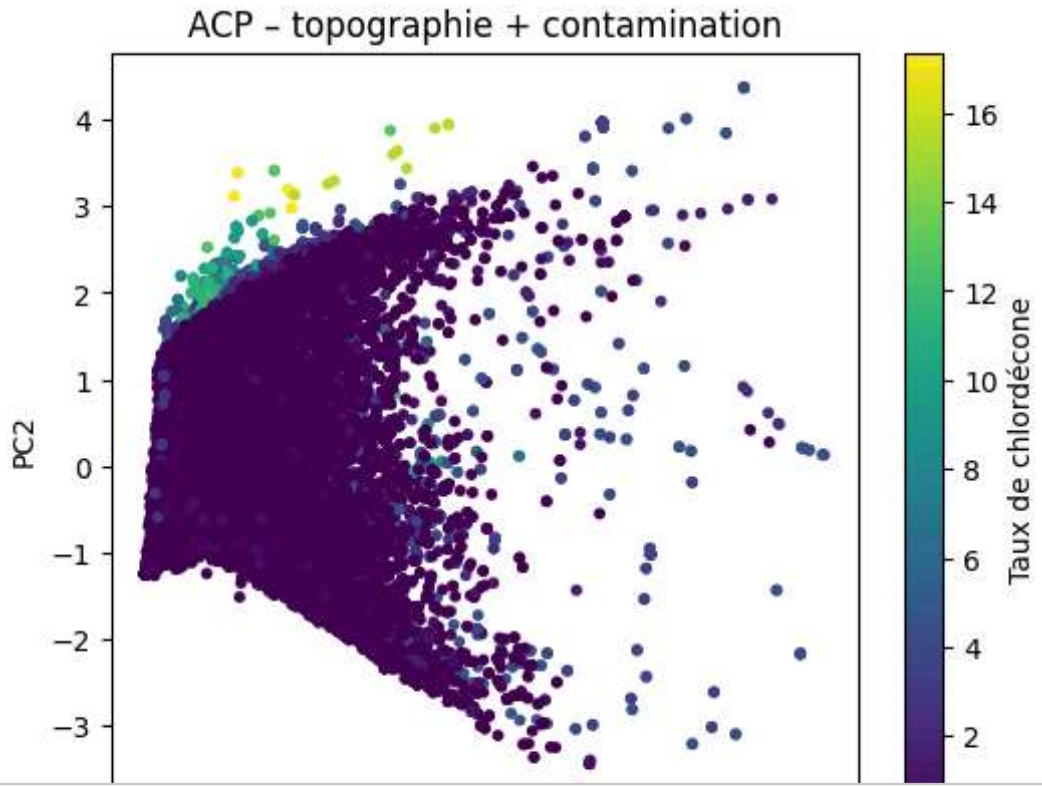

Interprétation

L'ACP montre que :

Le premier axe (PC1) est fortement lié à la pente, la rugosité et l'exposition. Il oppose les zones plates aux zones accidentées.

Le second axe (PC2) est influencé par le TPI et l'ombrage, reflétant la position relative dans le relief (crêtes, pentes, vallées).

Les parcelles fortement contaminées se regroupent dans une zone spécifique du plan factoriel, ce qui suggère que la topographie influence la rétention du chlordécone.

Les zones plates, humides et peu drainées semblent favoriser l'accumulation.

```
plt.tight_layout()
```

```
<Figure size 640x480 with 0 Axes>
```

25. Clustering K-means

```
kmeans = KMeans(n_clusters=4, random_state=42)
clusters = kmeans.fit_predict(X_scaled)
df.loc[X.index, "cluster_topo"] = clusters
df["cluster_topo"].value_counts()
```

cluster_topo	count
1.0	13685
2.0	8075
0.0	7971
3.0	1359

dtype: int64

Interprétation

Le clustering identifie quatre groupes distincts de parcelles :

Cluster 1 (le plus grand) : parcelles à contamination faible, topographie modérée.

Cluster 2 : parcelles en zones accidentées, contamination faible à modérée.

Cluster 0 : parcelles en zones plates, contamination modérée.

Cluster 3 (le plus petit) : parcelles très contaminées, souvent situées dans des zones à faible pente et sols andosoliques.

Le cluster 3 correspond clairement aux zones à risque élevé, ce qui en fait une cible prioritaire pour la surveillance et la gestion des sols.

26. Taux de chlordécone par cluster

```
plt.figure(figsize=(8,5))
sns.boxplot(data=df, x="cluster_topo", y="Taux_Chlordecone")
```
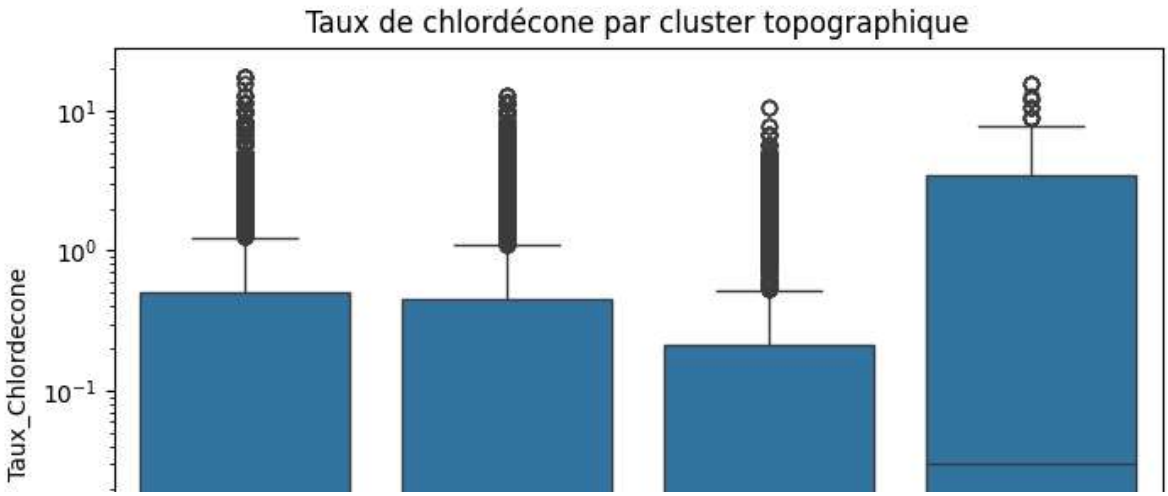
```
plt.yscale("log")
plt.title("Taux de chlordécone par cluster topographique")
plt.show()
```